

Causal Inference in Recommender Systems: A Survey and Future Directions

2023年5月14日 20:52

冒頭

レコメンデーションを用いて相関関係ではなく因果関係を抽出してシステムを強化しようと考えている

本文ではレコメンデーションと因果関係に基本概念をまとめ、その他文献について包括的にレビューする。また、研究領域における未解決の問題や将来の研究について議論する

イントロ

レコメンド

- CFとCB(クリックスルー率CTR)
- CF: 深層学習を用いた手法を用いている
- CTR: FMな、DeepFMなど高次特徴の学習を目指している

ユーザーサイドにおける因果関係

ユーザーの意思決定プロセスが因果関係によって起きる(ケータイを買った人がその後にバッテリーを買う)

因果関係の定義: 原因が結果の一部を担っている原因と結果で

因果推論は実験データや観察データに基づいて因果関係を決定し、活用するプロセス

- [64]ルービン因果モデル: ある治療法の効果を計算
- [57,59]構造的因果モデル: 構造法方程式を構築する

既存のレコメンドシステムの3つのボトルネック(因果推論が解決できるのではないかと考えられている)

- データバイアス: 収集データは適合性バイアス、人気バイアスなどのバイアス
- データの欠損、あるいはノイズ
- 精度以上の目標を達成するのは難しい(公平性、説明可能性、透明性等)

因果推論を用いた場合

バイアスを交絡因子とした因果グラフの構築→反実仮想推論によって欠損を回収

解釈可能な制御可能なモデルの構築

現在行われている因果推論に関する研究の分類

- データのバイアスの除去
- 因果推論を用いたデータ補強とノイズ除去。反実仮想推論
- 因果推論に基づく解釈可能・制御可能な推薦モデル説明可能性多様性公平性の達成

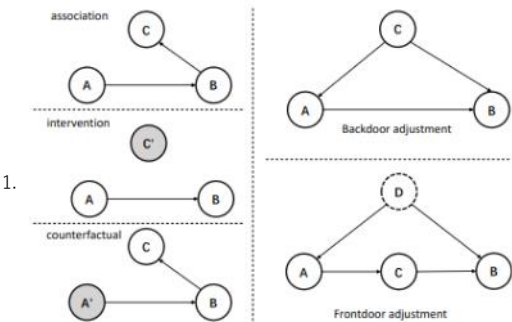
背景

因果推論の2つのフレームワーク

1. SCM(Structural Causal Models)
2. 潜在的フレームワーク
 - a. 結果関数に関する治療変数の因果効果を推定

違い: 論理的には平等

重要な違いは、潜在的な結果のフレームワークは、因果関係を記述するために因果グラフを考慮せず、因果効果を推定するためにグラフ上で推論を行わないことである



因果効果の推定と因果の発見。

観測データのみから因果関係を推定することが重要である。一般に、因果関係のある推定値は、まずSCMのような因果関係モデルを用いて統計的推定値に変換される。そして、その統計的推定値を観測データで推定する。つまり、因果モデルを定義することで、因果効果と治療と結果の間の交絡関連などの非因果効果を特定することができる。そして、観測データと特定された因果メカニズムを用いた推定により、因果効果を抽出する。

古典的な方法の1つはバックドア調整[59]である。

レコメンド

- 協調フィルタリング
 - MF
- クリックスルー率
 - 特徴量をユーザー、アイテムの相互作用にマッピングする
 - FMもそのひとつ

目的関数

推薦モデルに用いられる最適化関数

- Point-wise
 - ユーザーとアイテムの相互作用の予測に焦点を当てる
- Pair-wise

推薦システムの因果推論を導入する本質とメリットについて

3.1 レコメンドシステム

データバイアス：ユーザの好みを忠実に反映していない推薦データ
→人気バイアス、適合性バイアス

データでバイアス

交絡因子が入力と相互作用に同時に影響するバックドアパス
こちらの偽相関を無視すると人気バイアスが発生する(因果推論における交絡バイアス)
XがYにどれだけ影響を及ぼすのかを推定するためには因果推論技術が必要不可欠

因果推論を用いたデータ補強とノイズ除去

観測されたインタラクションデータは、レコメンダーシステム[65]の既に展開されている推薦方針によって制約を受ける(レコメンダーシステムの固有戦略と強く関連している)
現実の推薦システムでは、特徴収集のコストが高いため、ユーザやアイテムの特徴が欠落していることがある

因果推論を用いないデータ欠損問題の対処

- 欠落した評価に対する予測誤差を計算→精度が低い
 - 観察された各評価の重みを確率から評価する
- 因果推論ではデーター生成の因果的な記述を提供
- データ駆動型モデルの事前知識として機能する
- 従来の推薦手法では、ノイズの多いインタラクションを検出・除去することは困難である。Mahonyら[53]は、データノイズを自然ノイズと悪意あるノイズの2つに分類しています。自然なノイズは、推薦システムによるデータ収集手順の間に発生するノイズに関連し、悪意のあるノイズは、システムに意図的に挿入されるノイズを示す
- 自然なノイズが発生する理由
 - ユーザー自身の不正確な印象とデータ収集の誤り
 - ユーザーが自分の意見を離散的な評価にマッピングする際に、ノイズの多いデータが発生することを発見した
 - ストリーミングアプリケーションでは、変換イベントがデータ収集時に遅れてしまうことがあると主張した。
 - 電子商取引では、多くのクリックが購入に結びつかず、購入の大部分は最終的に否定的なコメントを得ることがある。現在、推薦システムで広く使われている暗黙のインタラクションデータは、ユーザーの第一印象が不正確であるため、ノイジーになりやすい。
 - 同じ映画に対して再評価を求められたときに、60%のユーザーしかその評価を維持しないことを示している。→解決策はわずか。
 - 因果推論に関しては、より徹底的で説明可能なユーザーモデリングを提供することができ、ノイズの多い相互作用を検出するのに役立つ。具体的には、反実仮想推論により、データ収集時にノイズがないことを想像することで、信頼性の高いラベルを生成できる。

精度を超えた関心ごと

説明可能性

あるアイテムが推薦され、あるアイテムが推薦されない理由(透明性と信頼)
既存の手法はまだ限定的(相関関係を用いた説明)
→因果推論のサポートなしに抽出すると誤った結論に至る可能性がある

多様な推薦のための一般的なCF手法とアルゴリズムに基づいて、フィルターバブルの形成を実証的に分析しました。人間の本性として、研究者は、人はコンフォートゾーンを追求し、自分が興味を持っている、あるいは同意している意見に留まることを望むことを発見しました[5]。長期的には、フィルターバブルは人々の視野を狭め、彼らの考えを先鋭化させる。したがって、フィルターバブルを解消し、推薦者の異質性を向上させることは緊急の課題である。

因果関係推論の必要性 偏ったデータから学習することで、レコメンド露出の均質性が悪化し、さらに収集したデータが偏るという偏ったフィードバックループは、フィルターバブルに対処する上で最も重大な課題の一つである。さらに、精度と多様性のジレンマも課題の一つであり、精度を追求すると多様性が低くなるという現象を指す。因果推論は、これらの課題に対処する機会を提供する。第一に、因果推論は、収集したデータの偏りや欠落を緩和し、未知のデータの探索を支援することができます。第二に、因果推論を強化したモデルは、ユーザー行動の下にある因果関係を利用し、ユーザーが特定のアイテムを消費する理由を理解することができます。これにより、既存のカテゴリ以外のアイテムを推奨することができ、ユーザーの需要に応えることができる。

公平性

性別によって不当に扱われるかどうかをより気にするユーザーもいれば、この問題に関して年齢を気にするユーザーもいる

→パーソナライズされることでの対処

あるユーザーがあるグループに属さない場合、あるいはあるアイテムが特定の属性を持たない場合、推薦結果は同じになるのか、あるいは推薦内容はどうなるのか、という反実仮想の世界での問いに答えることに似ている。

アイテム側の公平性問題としては、推薦される際に各アイテムが平等に扱われているかどうかを定義する。考えられる理由としては、特定の項目や属性の偏りや欠落が挙げられる。

因果推論に基づくレコメンデーションのための既存手法

データバイアス

1. 交絡効果
 - a. バイアスが引き起こされるのはほとんどこれ
 - i. SCMを用いた交絡効果の除去(バックドア調整、フロントドア調整)
 - b. 人気バイアス
 - i. アイテムの露出と観測された相互作用の両方に影響するアイテムの人気の交絡に起因する
 - ii. バックドア調整によって解決
 - 1) 近似演算子の提案
 - iii. フロントドア調整
 - 1) グローバルな交絡因子とパーソナライズされた交絡因子の両方に対処するためのいくつかの初期の試み
2. 衝突効果
 - a. 原因に特化したデータで学習することにより、関心と適合性の表現を分離し、ユーザー表現の頑健性と解釈可能性を向上させる。
3. 反交絡推論
 - a. デバイアスに使用されるもう一つのSCMベースの技術は、デバイアス推奨のためのパス固有の因果効果を排除する反事実推論
 - b. クリックベイト問題を軽減するために、露出度の高い特徴（例えば、魅力的なタイトル）の効果を除去するために反事実推論を行った。また、Weiら[96]は、人気バイアスを緩和するために、アイテムノードからランキングスコアへの直接的な因果関係を低減している。

データの欠落やノイズ

1. 因果推論のツールは、不十分な学習サンプルを補うための反実仮想データ、あるいはノイズの多いデータを調整するための反実仮想報酬を生成することによって、この2つの問題に取り組むために活用することができる
2. 推薦の観点からは、反実仮想データ増強は、事実データが収集されたときの実際のケースとは異なる状況下で、より多くのインタラクションを生成することを目的としている。

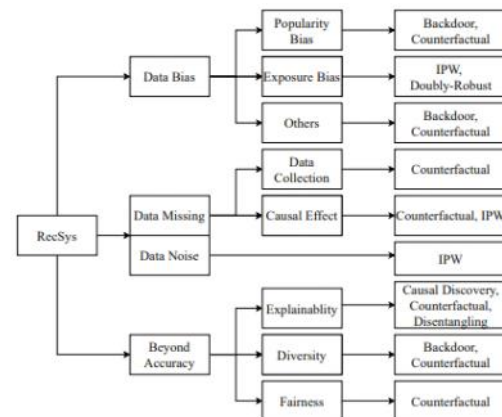


Fig. 5. Illustration of existing work of causal inference for recommendation.